Nhận diện thực thể tên riêng tiếng Việt (Vietnamese Named Entity Recognition)

Nguyễn Công Phát, Nguyễn Lê Phong, Phạm Trần Khánh Duy
23521143, 23521168, 23520384

Trường Đại học Công nghệ Thông tin – ĐHQG TP.HCM

GVHD: TS. Nguyễn Thị Quý

Mục lục

Mục lục

1.1. Giới thiệu bài toán NER

Định nghĩa

Nhận diện thực thể tên riêng (Named Entity Recognition - NER) là bài toán trong xử lý ngôn ngữ tự nhiên, nhằm **gán nhãn cho từng từ/token trong câu** để xác định các thực thể như *tên người (PER), tổ chức (ORG), địa danh (LOC), v.v.*

Ví dụ (BIO)

Hà_Nội/**B-LOC** là/O thủ_đô/O của/O Việt_Nam/**B-LOC** ./O

Ứng dụng

- Trích xuất thông tin trong tin tức, báo cáo.
- Hỗ trợ hệ thống hỏi đáp, tìm kiếm thực thể.
- Tiền xử lý cho dịch máy, tóm tắt văn bản.

Thách thức với tiếng Việt

- Tên riêng thường nhiều từ: *Thành_phố_Hồ_Chí_Minh*.
- Từ ghép không luôn có dấu cách rõ ràng.
- Ngữ cảnh phụ thuộc mạnh, khó đoán chỉ từ một token.
- Chữ hoa không nhất quán trong corpora tiếng Việt.
- Nhiều tên tổ chức dùng địa danh $\Rightarrow$ dễ nhầm ORG $\leftrightarrow$ LOC.
- Chất lượng tách từ ảnh hưởng trực tiếp tới NER.

1.2. Lý do chọn bài toán

Bối cảnh

- **Named Entity Recognition (NER)** là bài toán nền tảng trong xử lý ngôn ngữ tự nhiên.
- Đóng vai trò quan trọng trong các hệ thống *trích xuất thông tin, hỏi–đáp và phân tích văn bản*.
- Với **tiếng Việt**, NER gặp nhiều thách thức do:
  - Ngôn ngữ đa âm tiết, cấu trúc tên riêng phức tạp.
  - Hạn chế về dữ liệu gán nhãn chất lượng cao.

Phương pháp	Mô tả	Hạn chế
HMM	Mô hình xác suất gán nhãn chuỗi dựa trên xác suất chuyển trạng thái (transition) và phát xạ (emission).	Giả định Markov, không học được ngữ cảnh dài.
CRF	Mô hình xác suất có điều kiện, tối ưu xác suất toàn chuỗi nhãn.	Phụ thuộc nhiều vào đặc trưng thủ công (features).
BiLSTM–CRF	Kết hợp LSTM hai chiều (học ngữ cảnh) và CRF (gán nhãn).	Cần dữ liệu lớn, chi phí huấn luyện cao.
Transformers	Các công trình NER tiếng Việt gần đây chủ yếu khai thác *fine-tuning* PhoBERT, XLM–R hoặc mT5 để tận dụng ngữ cảnh sâu.	Tốn tài nguyên; nhiều nghiên cứu dùng dữ liệu tự xây dựng/mở rộng và không công bố đầy đủ code & dữ liệu ⇒ khó tái lập.

Bảng: Tổng quan các hướng tiếp cận NER và hạn chế trong bối cảnh tiếng Việt.

Mục tiêu đồ án

- So sánh định lượng ba mô hình: **HMM, CRF và BiLSTM–CRF**.
- Thực nghiệm trên cùng một tập dữ liệu chuẩn.
- Đánh giá mô hình bằng các độ đo phù hợp cho bài toán NER.
- Phân tích lỗi và tác động của các kỹ thuật tối ưu trong bối cảnh tiếng Việt.

1.3. Phát biểu bài toán

Input

- **Tập dữ liệu huấn luyện** gồm N câu đã gán nhãn theo chuẩn BIO:
  - Mỗi câu: dãy token $(w_1, w_2, \ldots, w_t)$ (token đã được tách sẵn trong dataset).
  - Mỗi token có nhãn tương ứng $(l_1, l_2, \ldots, l_t)$.
- **Câu mới cần dự đoán**: chuỗi token $(w_1, w_2, \ldots, w_t)$.

Output

- Chuỗi nhãn dự đoán $(l_1, l_2, \ldots, l_t)$ ứng với từng token.
- Mỗi nhãn thuộc tập nhãn L theo chuẩn BIO:
  - **B-** và **I-**: bắt đầu và bên trong một thực thể (PER, ORG, LOC, MISC).
  - **O**: token không thuộc thực thể nào.

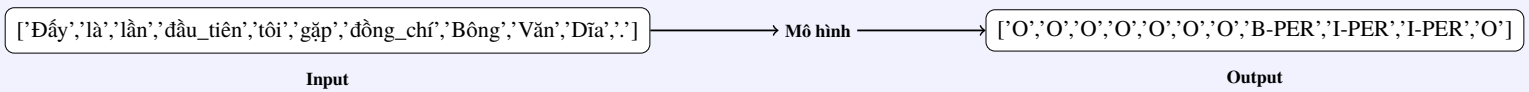

Mục lục

2.1. Mô hình Hidden Markov Model (HMM)

Tổng quan mô hình

- **Hidden Markov Model (HMM)** là mô hình xác suất dùng để gán nhãn chuỗi.
- Giả định tồn tại chuỗi trạng thái ẩn $Y = (y_1, \ldots, y_T)$ sinh ra chuỗi quan sát: $X = (x_1, x_2, \ldots, x_T)$
- Hai xác suất cốt lõi:
  - **Transition**: $P(y_t \mid y_{t-1})$
  - **Emission**: $P(x_t \mid y_t)$
- **Training:** ước lượng MLE;
- **Decoding:** Viterbi (tối ưu chuỗi nhãn).

Ưu điểm

- Dễ hiểu, nền tảng xác suất rõ ràng.
- Huấn luyện nhanh, phù hợp dữ liệu nhỏ.
- Mô hình hóa tốt bài toán gán nhãn chuỗi cơ bản.

Nhược điểm

- Giả định Markov bậc 1 $\Rightarrow$ chỉ phụ thuộc trạng thái trước.
- Không tận dụng được ngữ cảnh dài.
- Hiệu quả thấp với dữ liệu mất cân bằng nhãn (NER tiếng Việt).

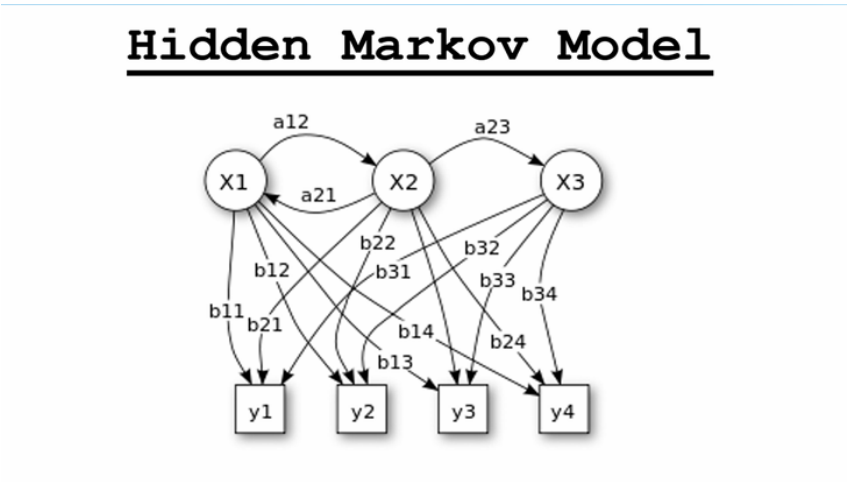

Sơ đồ HMM: trạng thái ẩn (Y) sinh ra quan sát (X).

Ví dụ cách HMM hoạt động trong NER

Câu:

Hà_Nội / là / thủ_đô / của / Việt_Nam / .

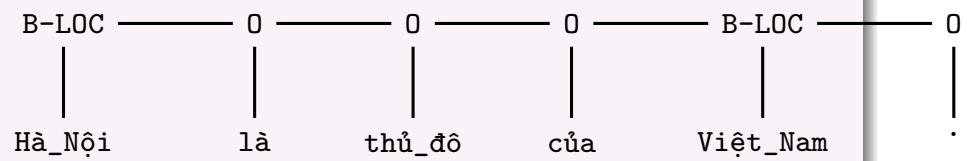

Viterbi chọn chuỗi $\hat{Y} = \arg\max_Y \prod_t P(y_t|y_{t-1})P(x_t|y_t)$

Chuỗi nhãn:

B-LOC O O O B-LOC O

HMM chọn chuỗi nhãn tối ưu dựa trên **xác suất chuyển nhãn** và **xác suất phát xạ**.

2.2. Cài đặt HMM trong bài toán

Cài đặt trong bài toán

Train + Decode:

1. Đếm *transition* $C(y_{t-1}, y_t)$ và *emission* $C(y_t, x_t)$ (có trọng số).
2. **Smoothing** (Xử lý zero probabilities): $P = \frac{C + \epsilon}{\sum C + |\mathcal{Y}|\epsilon}$, $\epsilon = 10^{-3}$.
3. Lấy log-prob, decode bằng Viterbi để ra chuỗi nhãn tốt nhất.

Trọng số lớp (mất cân bằng):

$$w(O) = 0.5, \quad w(y \neq O) = \min(5.0, \frac{\text{median\_freq}}{\text{count}(y)+10^{-5}})$$

Các cải tiến được áp dụng

- **Balanced sampling**: oversample câu chứa nhãn hiếm đến ngưỡng $\approx 0.5\times$ lớp lớn nhất.
- **Class weighting**: Điều chỉnh quá trình ước lượng xuất hiện của nhãn bằng cách gán trọng số khác nhau cho từng loại nhãn, thay vì coi tất cả như nhau. (Giới hạn trọng số lớp: `max_weight = 5.0`).
- **Focal adjustment (tag $\neq$ O)**: tăng xác xuất của các *emission và transition* hiếm bằng công thức:

$$p \leftarrow \min\left(1,\ p \cdot (1 + \alpha(1-p)^{\gamma})\right),\ \alpha = 0.1,\ \gamma = 2.0$$

Lưu ý: điều này khiến cho bảng xuất không còn là true probability mà được xem như score.

Pseudo-code (HMM + cải tiến)

```
# Input + hyper-params
Input: train_sents X, train_tags Y
Hyper: eps=1e-3, alpha=0.1, gamma=2.0,
       max_weight=5.0, w(O)=0.5

# 1) Imbalance handling
w(O)=0.5
w(y!=O)=min(max_weight,
     median_freq/(count(y)+1e-5))
X,Y = balanced_sampling(X,Y,
     target=0.5*max_class)

# 2) Weighted counts
C_tr[y_{t-1},y_t] += w(y_t)
C_em[y_t, x_t] += w(y_t)

# 3) Laplace smoothing
P_tr=(C_tr+eps)/(sum_next C_tr + |Y|*eps)
P_em=(C_em+eps)/(sum_word C_em + |V|*eps)

# 4) Focal adjustment (tag != O)
p = min(1, p*(1 + alpha*(1-p)^gamma))

# 5) Decode (Viterbi)
A=log(P_tr); B=log(P_em)
y_hat = Viterbi(A,B,x)
```

2.3. Mô hình Conditional Random Field (CRF)

Tổng quan

- **CRF** mô hình hoá trực tiếp xác suất có điều kiện toàn chuỗi: $P(Y \mid X)$.
- Không giả định độc lập Markov như HMM ⇒ khai thác **phụ thuộc nhãn liền kề** ⇒ biểu diễn trực tiếp mối quan hệ giữa các nhãn trong chuỗi..
- Giảm lỗi boundary (ví dụ `I-ORG` không thể theo sau `B-PER`)

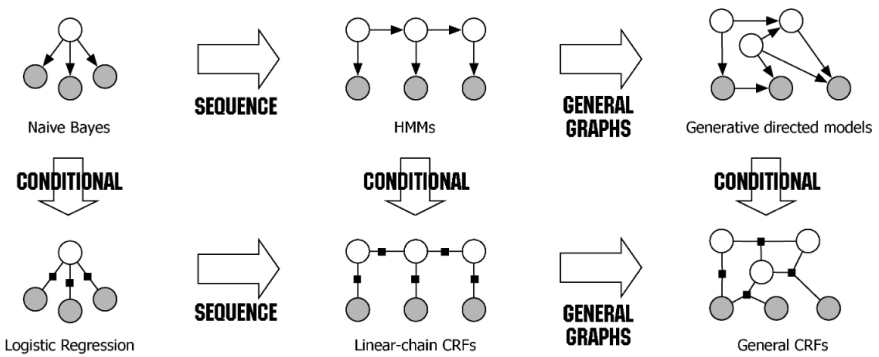

Sơ đồ mô hình CRF trong bài toán gán nhãn chuỗi.

Ví dụ: CRF xử lý một câu

Câu: `Hà_Nội / là / thủ_đô / của / Việt_Nam / .`

Cách CRF suy diễn: Trích đặc trưng token + ngữ cảnh ⇒ Kết hợp điểm nhãn và ràng buộc BIO ⇒ Viterbi chọn chuỗi nhãn tối ưu.

Kết quả: `B-LOC O O O B-LOC O`

Đặc trưng (Features) sử dụng

- Token hiện tại và các token lân cận (context window).
- Hình thái: `is_upper`, `is_title`, `is_digit`, dấu gạch dưới.
- Tiền tố / hậu tố (prefix, suffix).
- Vị trí câu: `BOS`, `EOS`.

Cài đặt CRF trong bài toán

- Thư viện: `sklearn-crfsuite`.
- Tối ưu: **L-BFGS** (`algorithm='lbfgs'`) – thuật toán tối ưu gradient hiệu quả cho CRF.
- Regularization: `c1=0.1` (L1) và `c2=0.1` (L2) nhằm giảm overfitting và kiểm soát độ phức tạp mô hình.
- `max_iterations=100`: giới hạn số vòng lặp huấn luyện để đảm bảo hội tụ.
- `all_possible_transitions=True`: cho phép xét cả các chuyển nhãn chưa xuất hiện trong tập huấn luyện, giúp mô hình xử lý tốt hơn các nhãn hiếm và giảm lỗi boundary.

Lý do lựa chọn cấu hình:
Các tham số được chọn nhằm cân bằng giữa khả năng tổng quát hóa và hiệu năng mô hình trên tập dữ liệu, đồng thời đảm bảo CRF khai thác hiệu quả ràng buộc chuỗi nhãn trong bài toán NER tiếng Việt.

2.4. Mô hình BiLSTM + CRF

Kiến trúc

1. **Embedding Layer:** ánh xạ token → vector ngữ nghĩa (Word Embedding).
2. **BiLSTM Layer:** học ngữ cảnh hai chiều (trước–sau) giúp nắm được phụ thuộc dài hạn.
3. **CRF Layer:** giải mã chuỗi nhãn hợp lệ tối ưu dựa trên toàn chuỗi.

Cài đặt trong bài toán

- **Embedding** được học **từ đầu** (random init), tối ưu cùng mô hình trên tập dữ liệu (không dùng pre-trained).
- **BiLSTM hai chiều** học ngữ cảnh trước–sau cho mỗi token.
- **CRF layer** áp đặt ràng buộc BIO và decode bằng **Viterbi**.
- Huấn luyện với **Adam**, `lr=0.001`, **early stopping = 5** để tránh overfitting.
- Tham số chính: `epochs=40`, `batch_size=256`.

Ví dụ: BiLSTM–CRF xử lý một câu

Câu:

`Hà_Nội / là / thủ_đô / của / Việt_Nam / .`

Quy trình:

- BiLSTM mã hoá mỗi token thành vector ngữ cảnh hai chiều.
- CRF kết hợp điểm phát xạ (từ BiLSTM) và điểm chuyển nhãn BIO.
- Viterbi chọn chuỗi nhãn tối ưu trên toàn câu.

Chuỗi nhãn dự đoán:

`B-LOC O O O B-LOC O`

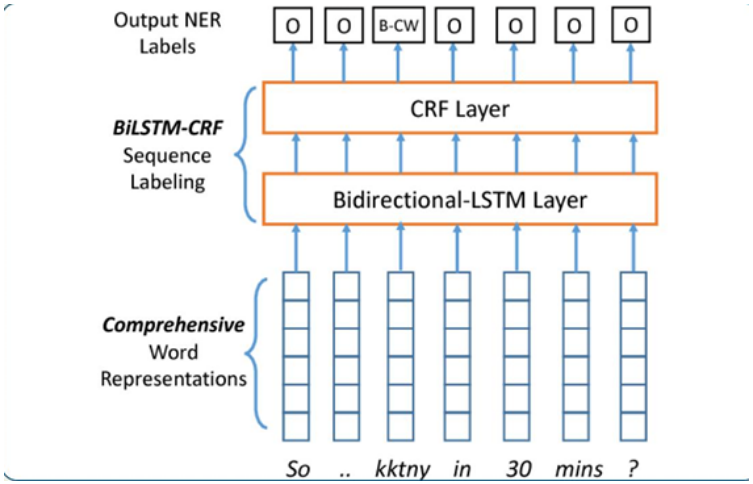

Sơ đồ kiến trúc BiLSTM + CRF: embedding → BiLSTM → CRF layer → nhãn NER.

Xác suất chuỗi nhãn trong CRF

$P(y_1, \ldots, y_T \mid x_1, \ldots, x_T) = \frac{1}{Z(x)} \exp\left(\sum_t \left(\text{score}(y_t, x_t) + \text{transition}(y_{t-1}, y_t)\right)\right)$ h_t là vector ngữ cảnh đầu ra của BiLSTM tại vị trí t.

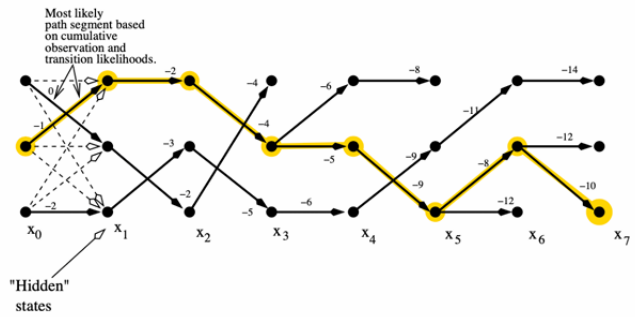

Thuật toán Viterbi: tìm chuỗi nhãn có xác suất cao nhất theo mô hình CRF.

Mục lục

3.1. Dataset

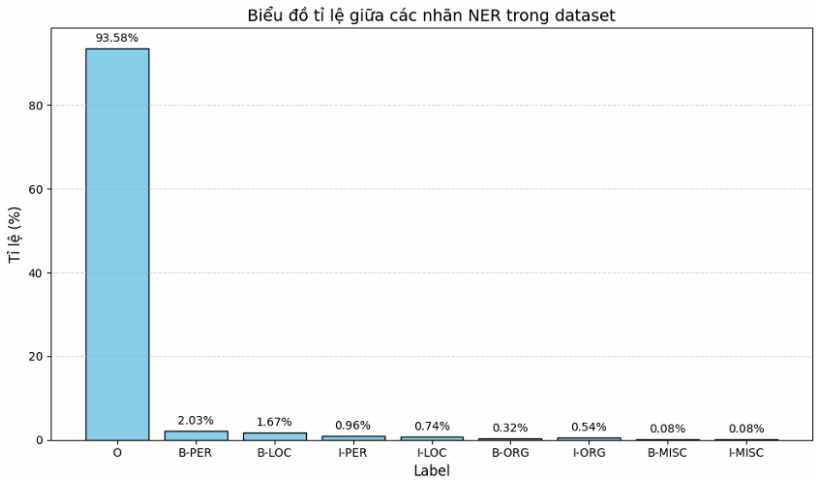

Biểu đồ tỉ lệ giữa các nhãn NER trong dataset.

Thành phần nhãn trong VLSP2016:

- **O (Outside):** 93.58%
- **B-PER:** 2.03%
- **B-LOC:** 1.67%
- **B-ORG:** 0.32%
- **Các nhãn I-/MISC khác:** ∼ 2.4%

Nhận xét dữ liệu

Dữ liệu **mất cân bằng nghiêm trọng**: nhãn O chiếm **93.58%** tổng token. Cần áp dụng *class weighting* hoặc *oversampling*.

Thông tin dữ liệu

Nguồn: VLSP2016-NER-data (HuggingFace)
Dạng dữ liệu: file `.parquet` / token + nhãn IOB.
Cấu trúc: cột 1 = token, cột 2 = tag (B-, I-, O-).
Quy mô: ∼13.5k câu train, ∼3.4k câu test (300k token).
Nhận xét: gán nhãn thủ công, khá sạch nhưng có thể nhiễu nhẹ.

Hệ thống nhãn BIO trong VLSP2016

Giá trị	Ý nghĩa	Loại thực thể
0	O – Outside	Không phải thực thể
1	B-PER (Begin of Person)	Bắt đầu tên người
2	I-PER (Inside Person)	Bên trong tên người
3	B-ORG (Begin of Org)	Bắt đầu tổ chức
4	I-ORG (Inside Org)	Bên trong tổ chức
5	B-LOC (Begin of Location)	Bắt đầu địa danh
6	I-LOC (Inside Location)	Bên trong địa danh
7	B-MISC (Begin of Misc)	Bắt đầu thực thể khác
8	I-MISC (Inside Misc)	Bên trong thực thể khác

3.2. Tiền xử lý dữ liệu

Quy trình xây dựng bộ ngữ liệu

- Tải dữ liệu **VLSP2016 NER từ Hugging Face**.
- Chuyển về định dạng dòng: `token<space>tag`, dòng trống ngăn cách câu.
- Gán `sentence_id` cho từng câu.
- Lưu ra `train.txt`, `test.txt`; loại bỏ dòng trống và token lỗi (không UTF-8).

Quy tắc tiền xử lý

- Giữ nguyên token đã tách sẵn trong dataset.
- Gán nhãn BIO/IOB song song với `sentence_id`.
- Chia dữ liệu theo câu thành **Train / Validation / Test** (phục vụ huấn luyện, chọn mô hình và đánh giá cuối).
- Tổng số câu: **13 486**; tổng số token: **294 501**.
- Tổng số thực thể (tag $\neq$ O): **18 901**.

Lưu ý: Validation set được dùng để chọn mô hình tốt nhất; Test set chỉ dùng để báo cáo kết quả cuối.

Nội dung văn bản	Ner_tags	Giải thích
["Cộng_tác_viên", "của", "Thanh", "ở", "Berlin", "tìm", "đến", "khu_vực", "xưa", "Hùng", "cư_trú", "."]	[0, 0, 1, 0, 5, 0, 0, 0, 0, 1, 0, 0]	"Thanh" được gán 1 → B-PER ⇒ bắt đầu một thực thể tên người. "Berlin" được gán 5 (sau từ "ở") → B-LOC ⇒ địa danh nổi tiếng (thủ đô của Đức). "Hùng" được gán 1 → B-PER ⇒ bắt đầu một tên người khác (Hùng cư trú tại Berlin).
["Người", "Việt", "sinh_sống", "ở", "17", "/", "19", "tỉnh", "vùng", "này", ",", "có", "thời_điểm", "lên", "đến", "10", "vạn", "người", "(", "những", "năm", "1946", "-", "1953", ")", "."]	[7, 8, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0]	"Người" → 7 = B-MISC "Việt" → 8 = I-MISC → Người Việt là thực thể thuộc nhóm MISC vì không thuộc vào 1 trong 3 loại nhãn PER, ORG, LOC.

Chú giải

- Mỗi dòng = 1 token + 1 nhãn (định dạng IOB/BIO).
- Dòng trống ngăn cách giữa các câu → gán `sentence_id`.
- Nhãn `B-/I-` xác định ranh giới và loại thực thể.
- Ví dụ: "Thanh" → B-PER, "Berlin" → B-LOC, "Người Việt" → B/I-MISC.

3.3. Các phương pháp đánh giá

Token-level Metrics (CoNLL) – Áp dụng: HMM / CRF / BiLSTM-CRF

$$\textbf{Precision} = \frac{TP}{TP + FP} \qquad \textbf{Recall} = \frac{TP}{TP + FN}$$

$$\textbf{F1} = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \qquad \textbf{Accuracy} = \frac{\#\text{token đúng}}{\#\text{token}}$$

Cách tính trung bình – Áp dụng: CRF / BiLSTM-CRF

- **Weighted**: có xét tần suất mỗi nhãn.
- **ALL**: tính trên toàn bộ nhãn (kể cả `O`).
- **Non-O**: chỉ xét token thuộc thực thể.

Token-level Evaluation (helpers) – Áp dụng: CRF / BiLSTM-CRF

- **ALL labels**: tính F1 weighted trên toàn bộ nhãn (kể cả `O`).
- **Non-O only**: loại bỏ `O`, chỉ đánh giá token thuộc thực thể.
- Dùng `classification_report` để xem Precision / Recall / F1 theo nhãn.

Span-level (Entity-level) – Áp dụng: CRF / BiLSTM-CRF

- Chuyển chuỗi BIO → danh sách span `(type, start, end)`.
- Đếm **TP / FP / FN** dựa trên span khớp hoàn toàn.
- Tính Precision / Recall / F1 ở mức **thực thể**.

Error Analysis – Áp dụng: CRF / BiLSTM-CRF

- **Confusion pairs**: thống kê cặp `(gold, pred)` sai nhiều nhất.
- Phát hiện lỗi phổ biến: `ORG` ↔ `LOC`, `PER` ↔ `O`.
- **Worst cases**: chọn câu có nhiều lỗi Non-O nhất để phân tích.

Ý nghĩa của các phương pháp đánh giá

- **Token-level metrics** phản ánh độ chính xác gán nhãn từng token, nhưng dễ bị chi phối bởi nhãn `O`.
- **Non-O evaluation** tập trung vào các token thuộc thực thể, giúp đánh giá thực chất khả năng nhận dạng NER.
- **Span-level metrics** đo chất lượng nhận dạng *thực thể hoàn chỉnh*, phù hợp với yêu cầu ứng dụng thực tế.
- **Error analysis** hỗ trợ phân tích lỗi phổ biến và định hướng cải tiến mô hình.

3.4. Kết quả thực nghiệm – HMM (Test set)

Trước cải thiện (Baseline HMM)

	precision	recall	f1-score	support
B-PER	0.89	0.82	0.85	1502
I-PER	0.73	0.85	0.79	692
B-LOC	0.81	0.61	0.69	1314
I-LOC	0.69	0.48	0.57	594
B-ORG	0.82	0.43	0.57	266
I-ORG	0.76	0.55	0.64	477
B-MISC	0.00	0.00	0.00	54
I-MISC	0.00	0.00	0.00	56
micro avg	0.81	0.66	0.73	4955
macro avg	0.59	0.47	0.51	4955
weighted avg	0.79	0.66	0.71	4955

Nhận xét:

- **Macro F1 thấp** (~0.51) ⇒ mô hình yếu ở nhãn hiếm.
- **B-MISC, I-MISC** có F1 = 0.00 (không nhận diện được).
- Dự đoán bị **chi phối bởi nhãn** O (mất cân bằng dữ liệu).

Sau cải thiện (Optimized HMM – Test set)

```
>>> Evaluating on Test Set...
              precision    recall  f1-score   support

       B-LOC       0.73      0.78      0.76      1314
      B-MISC       0.35      0.94      0.52        54
       B-ORG       0.53      0.76      0.62       266
       B-PER       0.85      0.88      0.87      1502
       I-LOC       0.72      0.71      0.71       594
      I-MISC       0.35      0.91      0.51        56
       I-ORG       0.60      0.67      0.63       477
       I-PER       0.79      0.87      0.83       692
           O       0.99      0.99      0.99     69944

    accuracy                           0.97     74899
   macro avg       0.66      0.83      0.72     74899
weighted avg       0.98      0.97      0.98     74899
```

Cải thiện đạt được:

- **Macro F1: 0.51 → 0.72**.
- Nhãn hiếm **B-MISC, I-MISC** đạt F1 **~0.5**.
- Recall các nhãn thực thể tăng (ít bỏ sót thực thể hơn).
- Hiệu quả từ: **Balanced Sampling, Class Weighting, Focal Adjustment**.

Nhận xét & đánh giá

- Tăng **Recall** ở nhãn hiếm ⇒ đôi khi **Precision** giảm là đánh đổi hợp lý.
- Tối ưu giúp giảm thiên lệch nhãn O; tuy nhiên HMM vẫn hạn chế do **Markov bậc 1**.

Tóm tắt (Test set)

Macro F1: **0.72** | **Weighted F1**: **0.98** | **Accuracy**: **0.97**

3.5. Phân tích lỗi – HMM

Các lỗi NER phổ biến (Top errors)

```
>>> Top NER Errors:
O -> B-LOC: 280
B-LOC -> O: 168
O -> I-ORG: 164
O -> B-PER: 156
O -> B-ORG: 131
I-ORG -> O: 94
O -> I-LOC: 82
B-PER -> O: 79
O -> B-MISC: 69
O -> I-MISC: 60
```

Nhận xét:

- Lỗi phổ biến nhất là **O → B-*/I-*** và **B-*/I-* → O**.
- Cho thấy mô hình vẫn **thiên lệch về nhãn** `O` dù đã tối ưu.
- Các thực thể dài (`ORG`, `LOC`) dễ bị **đứt chuỗi**.

Ví dụ câu bị gán nhãn sai

```
Sentence 8:
WORD            TRUE       PRED
-----------------------------------
Lại             O          O
một             O          O
lần             O          O
nữa             O          O
,               O          O
chính           O          O
ban             B-ORG      O          Wrong
quản_lí         I-ORG      O          Wrong
rừng_phòng_hộ   I-ORG      O          Wrong
đầu             I-ORG      O          Wrong
nguồn           I-ORG      O          Wrong
Sêrêpôk         I-ORG      O          Wrong
đã              O          O
"               O          O
thả_cửa         O          O
"               O          O
cho             O          O
sự              O          O
hình_thành      O          O
một             O          O
khu             O          O
du_lịch         O          O
trời_ơi         O          O
như_thế         O          O
...             O          O
```

Phân tích nguyên nhân:

- Cụm `ban quản_lí rừng_phòng_hộ đầu nguồn Sêrêpôk` là một thực thể **ORG** dài.
- HMM gán đúng `B-ORG` ở token đầu nhưng **mất toàn bộ chuỗi I-ORG phía sau**.
- Chỉ cần một token có **emission hoặc transition thấp** ⇒ toàn span bị gãy.
- Mô hình **không khai thác được ngữ cảnh dài** để duy trì chuỗi thực thể.

Kết luận

- Đây là **lỗi mang tính cấu trúc của HMM**. Do giả định **Markov bậc 1** và không có biểu diễn ngữ cảnh dài hạn, HMM dễ làm **đứt chuỗi các thực thể dài** như `ORG`.
- Các kỹ thuật tối ưu giúp cải thiện **Recall** cho nhãn hiếm, nhưng **không thể khắc phục triệt để** hạn chế này, là động lực để sử dụng các mô hình ngữ cảnh sâu hơn như **CRF** và **BiLSTM+CRF**.

3.6. Kết quả thực nghiệm – CRF (Test set)

Nhận xét tổng quan (Test set)

- **Accuracy rất cao**: **0.9904**.
- **Weighted F1 (ALL)**: **0.9901** (bao gồm nhãn `O`).
- **Non-O Weighted F1**: **0.9076** ⇒ nhận diện thực thể tốt.
- **Span-level F1**: **0.9191** (đánh giá ở mức thực thể hoàn chỉnh).

Ý nghĩa:

- CRF học được **phụ thuộc nhãn toàn chuỗi**, giảm lỗi đứt span.
- Hiệu quả rõ rệt với thực thể dài (`ORG`, `LOC`).
- Vượt trội so với HMM trong bài toán NER tiếng Việt.

So sánh theo đặc trưng (Test set)

Metric	Base	+Lower	+Pre/Suf	+Shape
Accuracy	0.9563	0.9850	0.9898	**0.9904**
Precision	0.9505	0.9843	0.9894	**0.9900**
Recall	0.9563	0.9850	0.9898	**0.9904**
F1-score	0.9484	0.9841	0.9895	**0.9901**

Shape features: `is_upper`, `is_title`, `is_digit`

Kết luận

CRF cho kết quả vượt trội nhờ mô hình hóa **phụ thuộc nhãn toàn chuỗi** và khai thác hiệu quả **đặc trưng hình thái + ngữ pháp**, đặc biệt phù hợp với NER tiếng Việt.

3.7. Phân tích lỗi – CRF

Top confusions (Test set)

```
Top confusions:
I-ORG -> O : 26
B-LOC -> O : 21
B-PER -> O : 20
B-ORG -> O : 19
O -> I-ORG : 18
B-LOC -> I-LOC : 14
O -> B-LOC : 12
I-LOC -> B-LOC : 11
O -> B-ORG : 10
B-PER -> B-LOC : 10
B-LOC -> B-PER : 9
I-PER -> I-ORG : 8
I-ORG -> B-LOC : 8
B-ORG -> I-ORG : 7
B-ORG -> B-LOC : 7
I-LOC -> O : 7
O -> I-LOC : 7
I-ORG -> I-LOC : 7
O -> B-PER : 6
I-PER -> O : 6
```

Nhận xét nhanh:

- Lỗi nổi bật là **I-ORG → O** và **B-ORG → O** ⇒ **đứt span ORG dài** (mất nhãn bên trong thực thể).
- Nhiều lỗi **B-LOC → O / I-LOC ↔ B-LOC** ⇒ sai **ranh giới thực thể** (boundary) trong chuỗi LOC.
- Nhầm **PER ↔ LOC** (vd: `B-PER -> B-LOC`, `B-LOC -> B-PER`) thường đến từ **viết hoa / token dạng tên riêng**.

Worst case (ví dụ tiêu biểu)

```
Worst cases:
idx=899 non0_errors=14
✗ Nhuận_Đức          gold=B-LOC    pred=O
✗ bót                gold=B-LOC    pred=O
✗ An_Nhơn_Tây        gold=I-LOC    pred=B-LOC
✗ bót                gold=B-LOC    pred=O
✗ Trung_Hoà          gold=I-LOC    pred=B-LOC
✗ bót                gold=B-LOC    pred=O
✗ Phú_Hoà_Đông       gold=I-LOC    pred=B-LOC
✗ bót                gold=B-LOC    pred=O
✗ cầu                gold=I-LOC    pred=B-LOC
✓ Bến_Mương          gold=I-LOC    pred=I-LOC
✓ huyện_lỵ           gold=B-LOC    pred=B-LOC
✓ Củ_Chi             gold=I-LOC    pred=I-LOC
✗ căn_cứ             gold=B-LOC    pred=O
✗ Đồng_Dù            gold=I-LOC    pred=B-LOC
✗ sư_đoàn            gold=B-ORG    pred=O
✗ dù                 gold=I-ORG    pred=O
✗ 25                 gold=I-ORG    pred=O
✓ Mỹ                 gold=B-LOC    pred=B-LOC
```

Giải thích nguyên nhân:

- Nhiều token **địa danh nhiều từ** bị gán `B-LOC` rồi các token sau lại rơi về `O` ⇒ **đứt chuỗi LOC** (boundary + transition yếu).
- Các token dạng **số / ký hiệu** (vd: `25`, `101`, `325`) làm nhiễu đặc trưng, dễ kéo nhãn `I-ORG` về `O`.
- Một số cụm có **từ khóa gợi ORG/LOC** (vd: `UBND`, `tỉnh`, `Uỷ_ban`) nhưng ngữ cảnh cụ thể không đủ mạnh ⇒ dễ nhầm **ORG ↔ LOC** hoặc **ORG → O**.

Thông điệp chính

Các đặc trưng hình thái & ngữ pháp giúp CRF nhận diện tốt hơn, nhưng vẫn khó với **thực thể dài** và **boundary LOC/ORG**.
Để giảm lỗi span dài & boundary, cần **ngữ cảnh mạnh hơn** (BiLSTM/Transformer) hoặc bổ sung **feature theo cụm từ / gazetteer** cho LOC/ORG.

3.8. Kết quả thực nghiệm – BiLSTM-CRF (Test set)

Kết quả trên Test set (BiLSTM-CRF)

```
[Token] Weighted F1 (ALL incl O): 0.9843
              precision    recall  f1-score   support

       B-LOC     0.9092    0.7694    0.8335      1314
      B-MISC     0.9259    0.9259    0.9259        54
       B-ORG     0.8361    0.5752    0.6815       266
       B-PER     0.9342    0.9268    0.9305      1502
       I-LOC     0.8933    0.7189    0.7966       594
      I-MISC     0.9091    0.8929    0.9009        56
       I-ORG     0.8420    0.6143    0.7103       477
       I-PER     0.9357    0.8829    0.9086       692
           O     0.9896    0.9979    0.9937     69944

    accuracy                         0.9851     74899
   macro avg     0.9083    0.8116    0.8535     74899
weighted avg     0.9843    0.9851    0.9843     74899

[Token] Weighted F1 (Non-O only): 0.8642
              precision    recall  f1-score   support

       B-LOC     0.9405    0.7694    0.8464      1314
      B-MISC     1.0000    0.9259    0.9615        54
       B-ORG     0.9217    0.5752    0.7083       266
       B-PER     0.9574    0.9268    0.9418      1502
       I-LOC     0.9242    0.7189    0.8087       594
      I-MISC     0.9259    0.8929    0.9091        56
       I-ORG     0.9099    0.6143    0.7334       477
       I-PER     0.9517    0.8829    0.9160       692

   micro avg     0.9437    0.8046    0.8686      4955
   macro avg     0.9414    0.7883    0.8532      4955
weighted avg     0.9417    0.8046    0.8642      4955

[Span] P=0.9253 R=0.8450 F1=0.8834 | TP=409 FP=33 FN=75
```

Tóm tắt chỉ số (Test set)

Nhận xét nhanh

- Token-level (ALL) cao do nhãn `O` chi phối ⇒ **Weighted F1 = 0.9843**.
- Khi chỉ xét **Non-O**, F1 giảm còn **0.8642** ⇒ khó ở thực thể hiếm/dài.
- Lỗi phổ biến: bỏ sót thực thể (dự đoán về `O`), đặc biệt **LOC/ORG**.

Token-level

- **ALL incl O:** Weighted F1 = **0.9843**, Acc = **0.9851**, Macro F1 = **0.8535**
- **Non-O only:** Weighted F1 = **0.8642**, Micro F1 = **0.8686**, Macro F1 = **0.8532**

Span-level (Entity-level)

P=**0.9253** | R=**0.8450** | F1=**0.8834**
TP=**409**, FP=**33**, FN=**75**

Kết luận

BiLSTM-CRF cải thiện biểu diễn ngữ cảnh so với HMM, nhưng trong đồ án này **CRF vẫn tốt hơn** (Non-O F1 và Span-F1 cao hơn) ⇒ đặc trưng thủ công + CRF phù hợp dữ liệu hiện tại.

3.9. Phân tích lỗi – BiLSTM-CRF

Top confusions (Test set)

```
Top confusions:
B-LOC -> O : 238
I-ORG -> O : 137
B-ORG -> O : 101
I-LOC -> O : 92
B-PER -> O : 91
I-PER -> O : 63
O -> B-LOC : 37
O -> B-PER : 36
B-LOC -> B-PER : 30
O -> I-ORG : 26
I-LOC -> B-LOC : 24
I-ORG -> B-LOC : 20
I-LOC -> I-PER : 20
O -> B-ORG : 17
O -> I-LOC : 16
B-LOC -> I-LOC : 16
I-LOC -> I-ORG : 15
I-ORG -> I-LOC : 14
I-LOC -> B-PER : 14
I-PER -> B-PER : 11
```

Nhận xét:

- Lỗi lớn nhất: **B-LOC** → **O** (238), **I-ORG** → **O** (137).
- Mô hình thường **bỏ sót thực thể** (FN tăng) ⇒ Recall span giảm.
- Có hiện tượng **nhầm ranh giới BIO**: `I-LOC` ↔ `B-LOC`, `B-LOC` → `B-PER`.

Ý nghĩa

Sai lệch chủ yếu đến từ **entity dài** và **tên riêng/viết tắt/ngoại ngữ** khiến emission không ổn định ⇒ dễ rơi về nhãn `O`.
⇒ **Kết luận:** BiLSTM-CRF học ngữ cảnh tốt hơn HMM, nhưng vẫn cần **feature/embedding mạnh hơn** hoặc **pretrained encoder** (PhoBERT/XLM-R) để xử lý entity dài và tên riêng đa dạng.

Ví dụ worst case (Test set)

```
Worst cases:
idx=2662 nonO_errors=14
✓ Jane                gold=B-PER      pred=B-PER
✓ Barton              gold=I-PER      pred=I-PER
X quản_lý             gold=O          pred=B-ORG
X Bệnh_viện           gold=B-LOC      pred=I-ORG
X Washington          gold=I-LOC      pred=I-ORG
X ;                   gold=O          pred=I-ORG
X Sophie              gold=B-PER      pred=I-ORG
X Quinn               gold=I-PER      pred=I-ORG
✓ VN                  gold=B-LOC      pred=B-LOC
✓ Trung_tâm           gold=B-ORG      pred=B-ORG
✓ Nghiên_cứu          gold=I-ORG      pred=I-ORG
✓ về                  gold=I-ORG      pred=I-ORG
✓ triết_học           gold=I-ORG      pred=I-ORG
X ,                   gold=I-ORG      pred=O
X văn_hoá             gold=I-ORG      pred=O
X và                  gold=I-ORG      pred=O
X xã_hội              gold=I-ORG      pred=O
X VN                  gold=I-ORG      pred=B-LOC
X Trường              gold=B-ORG      pred=B-LOC
X ĐH                  gold=I-ORG      pred=I-LOC
X Temple              gold=I-ORG      pred=O
✓ Nguyễn              gold=B-PER      pred=B-PER
✓ Thị                 gold=I-PER      pred=I-PER
✓ Mai                 gold=I-PER      pred=I-PER
✓ Quảng_Nam           gold=B-LOC      pred=B-LOC
```

Giải thích nguyên nhân:

- Câu chứa nhiều thực thể dài/đan xen (ORG–LOC–PER) ⇒ khó giữ ranh giới span.
- Một vài token "nhiễu" (dấu câu, viết tắt như `ĐH`, `VN`, tên ngoại như `Temple`) làm CRF layer khó nối chuỗi `I-*`.
- Khi **một token bị gán O**, cả thực thể dài có thể bị **đứt chuỗi** ⇒ giảm F1 span.

3.10. So sánh tổng quan các mô hình

Nhận xét so sánh mô hình

- **CRF tốt nhất** (Test): **Acc=0.9904**, **Span-F1=0.9191**, **Non-O F1=0.9076**.
- **BiLSTM+CRF** đứng sau: **Acc=0.9851**, **Span-F1=0.8834**, **Non-O F1=0.8642**.
- **HMM (tối ưu)**: Macro-F1 **0.51→0.72**, nhưng vẫn kém do hạn chế Markov.
- **Token F1 (ALL)** cao vì O nhiều ⇒ ưu tiên **Non-O F1** & **Span-F1**.

Kết luận ngắn

- **CRF phù hợp nhất** với dữ liệu hiện tại (feature thủ công + ràng buộc chuỗi).
- **BiLSTM+CRF** sẽ mạnh hơn nếu có **data lớn hơn / embedding pretrained**.

Bảng so sánh hiệu suất (Test set)

Chỉ số	HMM	CRF	BiLSTM
Accuracy	0.97	**0.9904**	0.9851
Token F1 (ALL incl O)	0.98	**0.9901**	0.9843
Token F1 (Non-O only)	–	**0.9076**	0.8642
Macro F1 (Token)	**0.72**	0.8875	0.8535
Span F1 (Entity-level)	–	**0.9191**	0.8834

Ghi chú: HMM có Macro/Weighted/Acc; CRF/BiLSTM-CRF có thêm Non-O & Span-F1.

Ý nghĩa chỉ số

- **Token F1 (ALL)**: dễ "ảo" vì O nhiều.
- **Non-O F1**: chất lượng nhận diện thực thể (bỏ O).
- **Span F1**: đúng thực thể hoàn chỉnh (khắt khe nhất).

Mục lục

Kết luận & Hướng phát triển

Kết luận từ thực nghiệm

- Ba mô hình **HMM, CRF và BiLSTM+CRF** đều áp dụng được cho bài toán **Named Entity Recognition (NER) tiếng Việt** trên bộ dữ liệu **VLSP 2016**.
- **CRF cho kết quả tốt nhất trên Test set**: **Accuracy = 0.9904**, **Non-O F1 = 0.9076**, **Span-F1 = 0.9191**, cho thấy khả năng nhận diện thực thể **ổn định và chính xác ở mức entity hoàn chỉnh**.
- Kết quả này khẳng định **đặc trưng hình thái & ngữ pháp** (lowercase, prefix/suffix, word shape, is_upper, is_title, is_digit) vẫn **rất hiệu quả với tiếng Việt** khi kết hợp cùng CRF.
- **BiLSTM+CRF** đạt kết quả tốt nhưng thấp hơn CRF (**Non-O F1 = 0.8642**, **Span-F1 = 0.8834**), nguyên nhân chủ yếu do **dữ liệu huấn luyện chưa đủ lớn** và **chưa sử dụng embedding pretrained**.
- **HMM (tối ưu)** cải thiện đáng kể Macro-F1 (**0.51** $\rightarrow$ **0.72**), nhưng vẫn bị giới hạn bởi **giả định Markov bậc 1** và không mô hình hóa được ngữ cảnh dài.

Hướng phát triển

Ngắn hạn:

- Bổ sung **gazetteer / từ điển tên riêng** cho CRF để cải thiện nhận diện **thực thể hiếm và thực thể dài**.
- Kết hợp **đặc trưng ký tự** (character-level) thông qua các mô hình **BiLSTM–CNN–CRF**.

Dài hạn:

- Fine-tune các mô hình ngôn ngữ pretrained cho tiếng Việt như **PhoBERT**, **XLM-R** kết hợp với CRF/Viterbi ở đầu ra.
- Khai thác các hướng **few-shot / zero-shot NER** với các mô hình mới như **GLiNER (2024)** để giảm phụ thuộc vào dữ liệu gán nhãn.
- Đóng gói hệ thống thành **pipeline suy diễn hoặc API** phục vụ các ứng dụng thực tế như chatbot, tìm kiếm, trích xuất thông tin.

Phân công công việc nhóm

Thành viên	MSSV	Vai trò chính
Nguyễn Công Phát (Nhóm trưởng)	23521143	Phụ trách chính toàn bộ dự án: thiết kế pipeline, cài đặt **HMM** và **CRF**, xử lý – chuẩn hoá dữ liệu, tối ưu **Focal Loss**, viết báo cáo tổng hợp, hoàn thiện slide thuyết trình.
Phạm Trần Khánh Duy	23520384	Phát triển và huấn luyện mô hình **BiLSTM–CRF**, thực hiện phân tích kết quả và đánh giá hiệu năng, tham gia viết phần kết quả thực nghiệm.
Nguyễn Lê Phong	23521168	Cài đặt mô hình **CRF**, xử lý đặc trưng, hỗ trợ tổng hợp báo cáo và trình bày phần **kết luận–hướng phát triển**.

Tài liệu tham khảo

- J. Lafferty, A. McCallum, F. Pereira (2001). *Conditional Random Fields: Probabilistic Models for Segmenting and Labeling Sequence Data*. ICML.
- Z. Huang, W. Xu, K. Yu (2015). *Bidirectional LSTM-CRF Models for Sequence Tagging*. arXiv:1508.01991.
- A.-D. Nguyen, K.-H. Nguyen, V.-V. Ngo (2018). *Neural Sequence Labeling for Vietnamese POS Tagging and NER*. arXiv:1811.03754v2.
- VLSP 2016. *Vietnamese Named Entity Recognition Shared Task Dataset*. (HuggingFace).

Cảm ơn!

Xin cảm ơn cô Nguyễn Thị Quý và các bạn!

Hỏi đáp — Demo